



CS 412 Intro. to Data Mining

Chapter 3. Data Preprocessing

การจัดเตรียม Data ก่อนที่จะไปประมวลผล

Jiawei Han, Computer Science, Univ. Illinois at Urbana-Champaign, 2017



Chapter 3: Data Preprocessing

- Data Preprocessing: An Overview

- Data Cleaning

Data ที่เก็บมา มันอาจมี noise

เก็บเอง
sensor - เก็บค่าไต่ค่า
มี noise, missing ในเซ็นเซอร์
ข้อมูลที่ไม่ได้กรอง
เป็นข้อมูลที่ไม่เข้ากับพวก

- Data Integration

เอา Data จากแหล่งไหนมารวมกัน

- Data Reduction and Transformation

ลดขนาด Data

ลดจำนวน Dimension ลดจำนวนตัว

- Dimensionality Reduction

- Summary

What is Data Preprocessing? — Major Tasks

2
ข้อมูลที่มี

- **Data cleaning**

- Handle missing data, smooth noisy data, identify or remove outliers, and resolve inconsistencies

ข้อมูล missing

กำจัด noisy

กำจัด outliers

จัดการ inconsistencies

ลบค่าจาก mean data
ให้ข้อมูลแม่นยำ

↓
ข้อมูลที่ผิดปกติ

- **Data integration**

- Integration of multiple databases, data cubes, or files

- **Data reduction** ลดจำนวนข้อมูล

- Dimensionality reduction
- Numerosity reduction
- Data compression

เปลี่ยนรูปแบบข้อมูล

- **Data transformation and data discretization**

- Normalization
- Concept hierarchy generation

Why Preprocess the Data? — Data Quality Issues

- Measures for data quality: A multidimensional view
 - Accuracy: ^{ໄປຫາຂໍ້ຜິດພາດ / ຈຳນວນຂໍ້ຜິດພາດທັງໝົດ / ພຶດ} correct or wrong, accurate or not
 - Completeness: not recorded, unavailable, ...
 - Consistency: some modified but some not, dangling, ...
 - Timeliness: ^{ກວດກາໃນເວລາໃດ} timely update? → ດັ່ງເຕັມການກວດກາ
 - Believability: ^{ສຳນຳຂໍ້ມູນທີ່ຖືກຕ້ອງ?} how trustable the data are correct?
 - Interpretability: how easily the data can be understood?

Data Cleaning

- Data in the Real World Is Dirty: Lots of potentially incorrect data, e.g., instrument faulty, human or computer error, and transmission error
- Incomplete: lacking attribute values, lacking certain attributes of interest, or containing only aggregate data
 - e.g., *Occupation* = “ ” (missing data)
- Noisy: containing noise, errors, or outliers
 - e.g., *Salary* = “-10” (an error)
- Inconsistent: containing discrepancies in codes or names, e.g.,
 - *Age* = “42”, *Birthday* = “03/07/2010”
 - Was rating “1, 2, 3”, now rating “A, B, C”
 - discrepancy between duplicate records
- Intentional (e.g., *disguised missing data*)
 - Jan. 1 as everyone’s birthday?

ไม่ตรงกับสิ่งที่ควร

มีด.จำเป็น

ไม่ตรงกับข้อมูล

ทำการดัดแปลงข้อมูล
ผิด

ข้อมูลไม่สอดคล้องกัน

Incomplete (Missing) Data

Data ไม่สมบูรณ์

- Data is not always available
 - E.g., many tuples have no recorded value for several attributes, such as customer income in sales data
- Missing data may be due to เกิดจากอะไรที่ไม่กรอกข้อมูล จึงเกิด Missing
 - Equipment malfunction
 - Inconsistent with other recorded data and thus deleted ไม่สอดคล้อง
 - Data were not entered due to misunderstanding เข้าใจผิด
 - Certain data may not be considered important at the time of entry
 - Did not register history or changes of the data ข้อมูลเปลี่ยนแปลง
- Missing data may need to be inferred

→ บางครั้งอาจจะประมาณค่าขึ้นมาได้

How to Handle Missing Data?

- Ignore the tuple: usually done when class label is missing (when doing classification)—not effective when the % of missing values per attribute varies considerably *Data record ที่มี Missing ค่าก็ลบทิ้งไป*
- Fill in the missing value manually: tedious + infeasible?
- Fill in it automatically with *อัตโนมัติ*
 - a global constant : e.g., “unknown”, a new class?!
 - the attribute mean *เอาค่า Mean มาแทนค่า Missing*
 - the attribute mean for all samples belonging to the same class: smarter *mean ที่*
 - **the most probable value: inference-based such as Bayesian formula or decision tree** *ใช้ class เดียวกัน*